Datos espaciales y redes para datos geográficos

Big Data y Machine Learning para Economía Aplicada

Ignacio Sarmiento-Barbieri

Universidad de los Andes

Agenda

1. Motivación
2. Datos espaciales
3. Dependencia espacial
4. Validación cruzada espacial
5. Imágenes satelitales
6. Transfer learning
7. Aplicaciones
8. Cierre

Recap

- La red densa no sabe qué píxeles son vecinos: aprende igual con los píxeles permutados.
- Una CNN mete esa estructura en el modelo: cada capa es un promedio ponderado de los vecinos, con los mismos pesos en todas partes.

Motivación

- Buena parte de los datos que usamos en economía aplicada tienen ubicación: viviendas, firmas, colegios, crímenes, lotes, municipios.
- Son el subproducto de una acción: vender una casa, pagar con tarjeta, moverse de un punto a otro.
- La ubicación entra en un modelo de dos maneras distintas:
  1. **Como fuente de variables**: distancias, vecinos, imágenes satelitales.
  2. **Como estructura de dependencia**: observaciones cercanas se parecen, y eso cambia cómo validamos.

Agenda

1. Motivación
2. Datos espaciales
3. Dependencia espacial
4. Validación cruzada espacial
5. Imágenes satelitales
6. Transfer learning
7. Aplicaciones
8. Cierre

Tipos de datos espaciales

Los datos espaciales vienen en cuatro formas básicas:

- **Puntos**: una coordenada por observación (una vivienda, un crimen).
- **Líneas**: secuencias de puntos (calles, ríos, rutas).
- **Polígonos**: áreas cerradas (barrios, UPZ, municipios).
- **Raster**: una grilla de celdas con un valor cada una (imágenes satelitales, luces nocturnas, elevación).

Tipos de datos espaciales: puntos

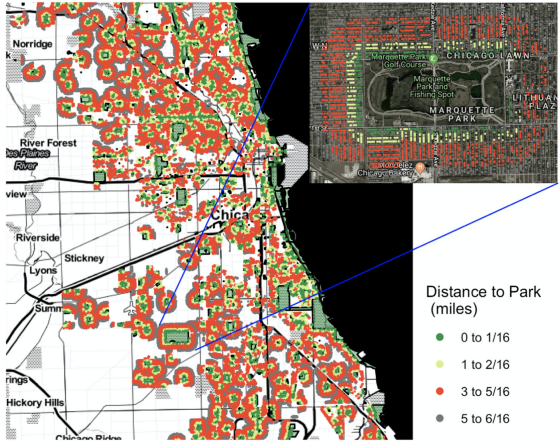


Fig. 1. Housing transactions around parks: neighborhood distance intervals. Notes: The following figure shows transactions within 3/8 miles of the nearest park in Chicago. The zoom in figure represents the 'neighborhood' around Marquette Park. It contains all of the transactions (4623) within three-eights of a mile that are not closer to another a park. Colors correspond to different distance intervals or 'bands' around the park. (For interpretation of the references to color in this figure legend, the reader is referred to the web version of this article.)

Source: Albouy, Christensen & Sarmiento-Barbieri (2020)

Tipos de datos espaciales: líneas

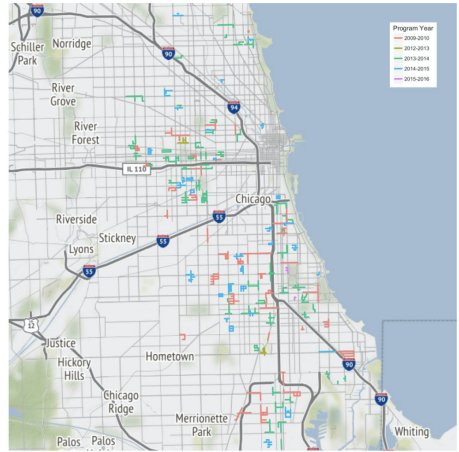
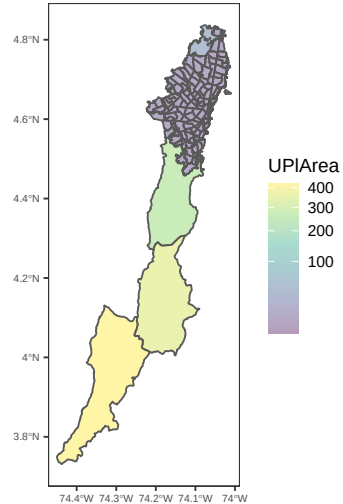


Fig. 1. Safe Passage Routes, by year of program adoption.
Note: Shapefiles with Safe Passage shape and location where obtained from the Chicago Data Portal and year that the program was launched at each location through a FOIA request.

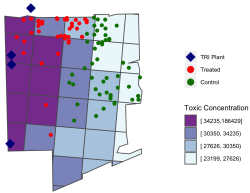
Source: McMillen, Sarmiento-Barbieri & Singh (2019)

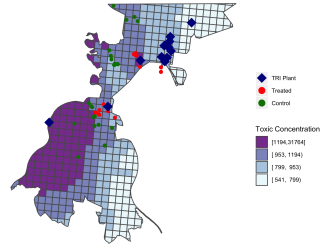
Tipos de datos espaciales: polígonos



Unidades de Planeamiento Zonal (UPZ), Bogotá

Tipos de datos espaciales: raster

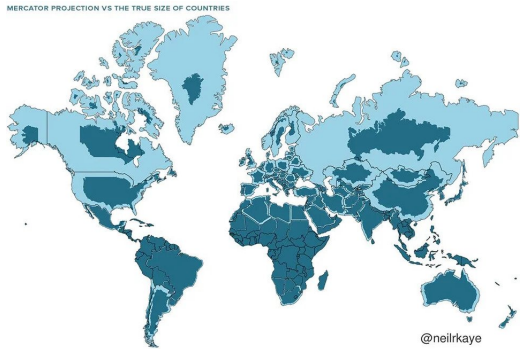




Source: Christensen, Sarmiento-Barbieri & Timmins (2022)

Sistemas de coordenadas

- La Tierra es un elipsoide irregular; los mapas y las pantallas son planos.
- Una **proyección** lleva el elipsoide al plano, y siempre distorsiona algo: áreas, distancias o ángulos.



Mercator vs. el tamaño real de los países. Source: https://thetruesize.com/

¿Qué proyección uso?

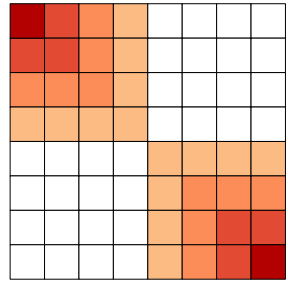
- "There exist no all-purpose projections, all involve distortion when far from the center of the specified frame" (Bivand, Pebesma & Gómez-Rubio, 2013).
- Muchas veces no lo decidimos nosotros: la agencia que produce los datos ya eligió. Con datos locales, conviene trabajar en el sistema de coordenadas (CRS) de la fuente.
- Lo que sí importa en la práctica:
  - Todas las capas en el **mismo** CRS antes de cruzarlas.
  - Para medir distancias en metros, un CRS proyectado (p.ej. MAGNA-SIRGAS / Origen Nacional en Colombia, EPSG:9377), no latitud y longitud en grados.

Agenda

1. Motivación
2. Datos espaciales
3. Dependencia espacial
4. Validación cruzada espacial
5. Imágenes satelitales
6. Transfer learning
7. Aplicaciones
8. Cierre

Dependencia espacial

- "Everything is related to everything else, but near things are more related than distant things" (Tobler, 1970).
- La **autocorrelación espacial** mide cuánto se parece una variable a sí misma en el espacio (Cliff & Ord, 1973).
- Positiva: unidades cercanas se parecen más que unidades lejanas.



Dependencia espacial

- Formalmente, para observaciones y_i, y_j en ubicaciones distintas:

$$\text{Cov}(y_i, y_j) \neq 0 \qquad \text{para } i \neq j$$

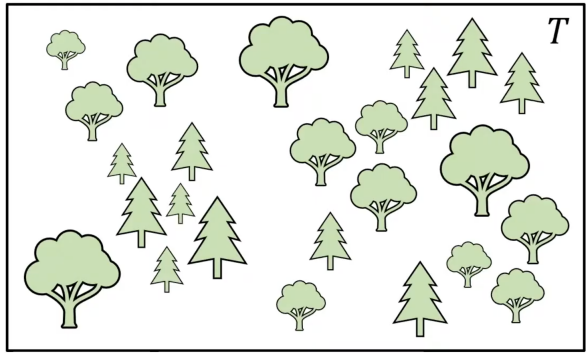
Agenda

1. Motivación
2. Datos espaciales
3. Dependencia espacial
4. Validación cruzada espacial
5. Imágenes satelitales
6. Transfer learning
7. Aplicaciones
8. Cierre

Predicción espacial y validación cruzada

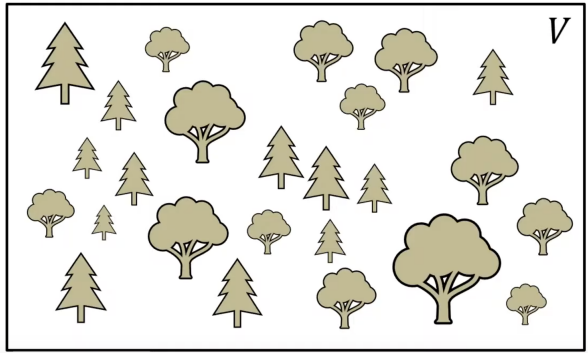


Predicción espacial y validación cruzada



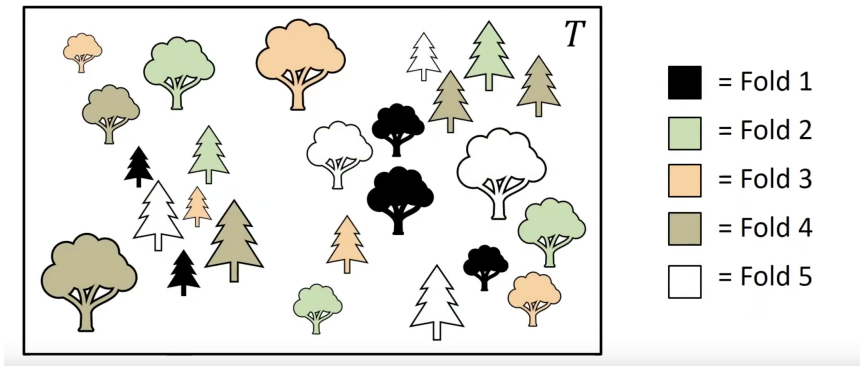
- Entrenamos con los árboles que medimos: el conjunto de entrenamiento $\mathcal{T}$.

Predicción espacial y validación cruzada



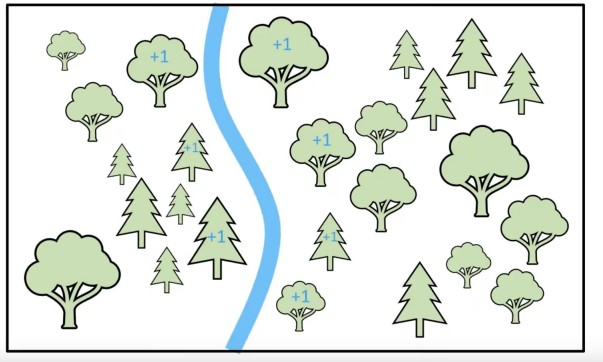
- Queremos predecir en otro bosque, $\mathcal{V}$, que el modelo nunca vio.

Predicción espacial y validación cruzada



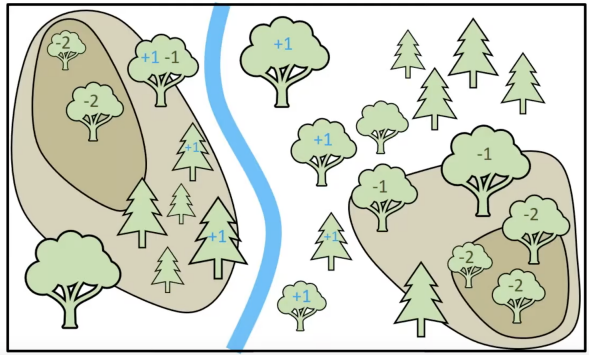
- Para estimar el error fuera de muestra, hacemos lo de siempre: CV con $K = 5$ folds asignados al azar.

Predicción espacial y validación cruzada



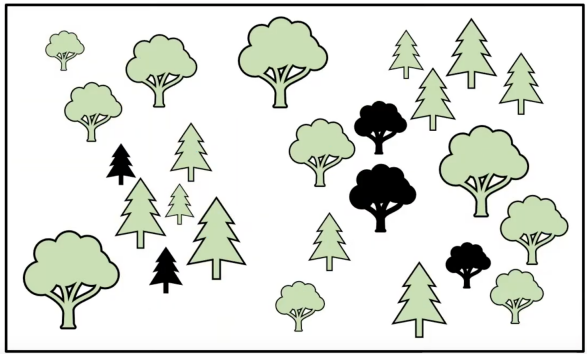
- Pero los árboles cerca del río crecen más: tienen un shock común (+1) que no está en sus atributos.

Predicción espacial y validación cruzada



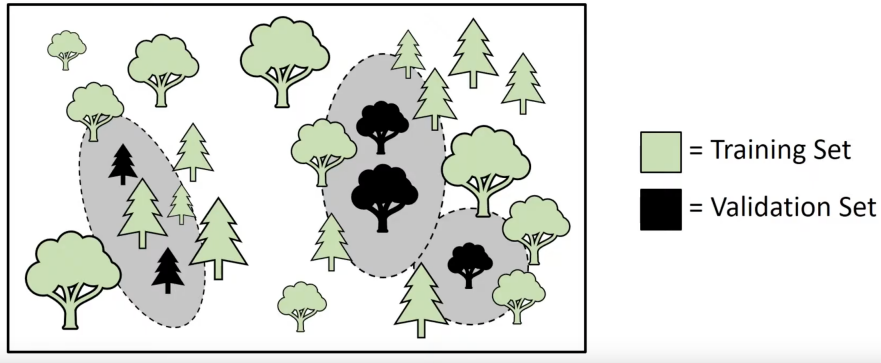
- Y hay manchas con shocks negativos (-1, -2): suelo más pobre, una plaga. El ruido tiene estructura espacial.

Predicción espacial y validación cruzada



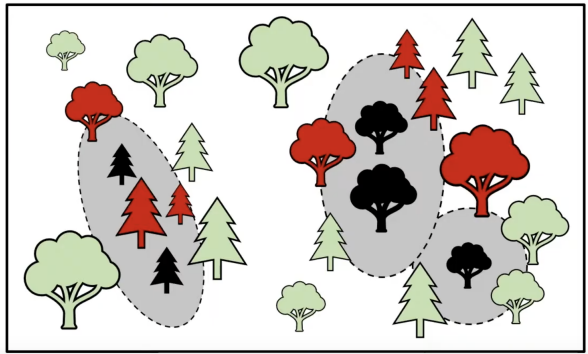
- Un fold de validación aleatorio: sus árboles están dispersos por todo el bosque.

Predicción espacial y validación cruzada



- Cada árbol de validación comparte mancha con árboles de entrenamiento...

Predicción espacial y validación cruzada

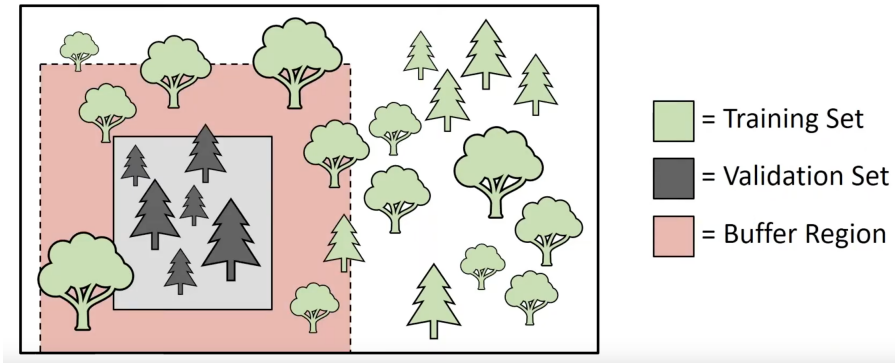


= Training Set

= Validation Set

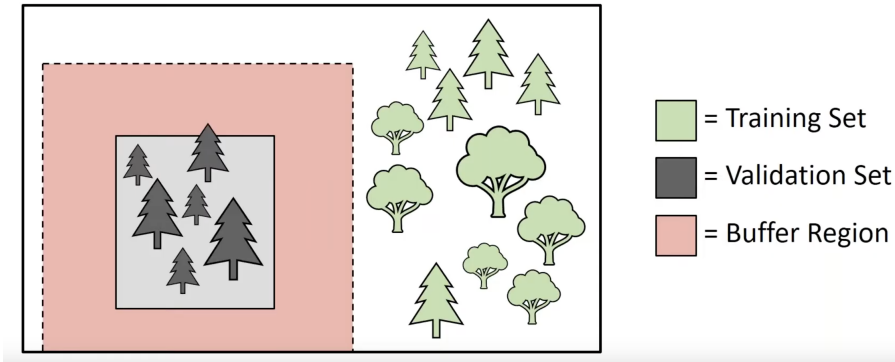
El modelo sencillo

CV espacial: buffers



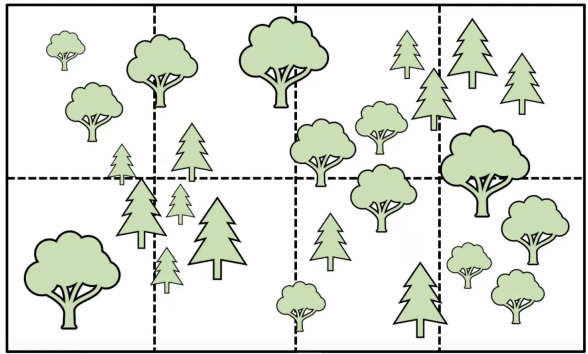
- … y sacamos del entrenamiento una franja alrededor (*buffer*), para que $\rho \approx 0$ entre entrenamiento y validación.

CV espacial: buffers



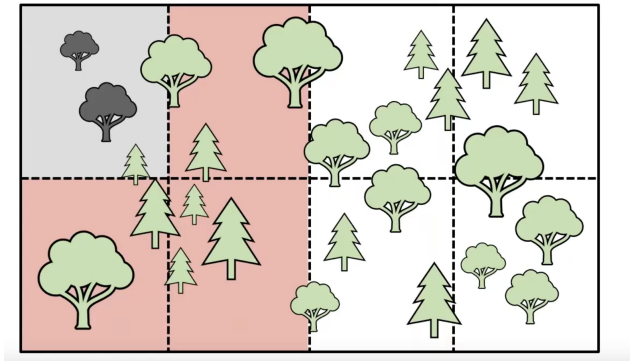
- El buffer no se usa ni para entrenar ni para validar. Su ancho debería ser del orden de la distancia a la que el ruido deja de estar correlacionado.

CV espacial: bloques



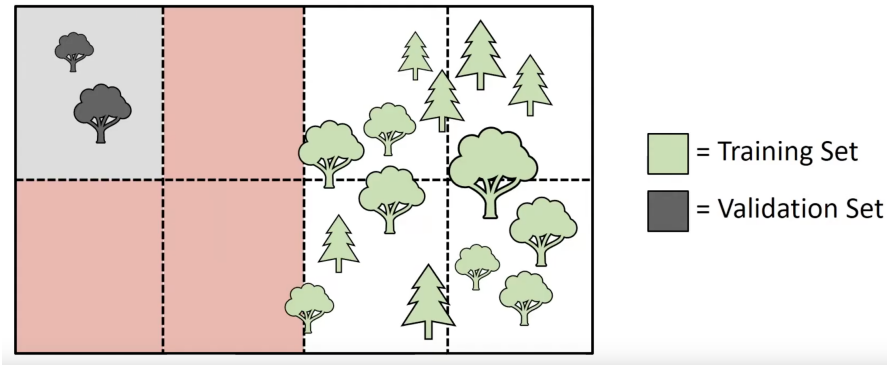
- Dividimos el espacio en bloques y asignamos **bloques enteros** a cada fold (Roberts et al., 2017).

CV espacial: bloques



- Un bloque valida; los vecinos pueden hacer de buffer; el resto entrena.

CV espacial: bloques



- Se repite con cada bloque, como en la CV de siempre. Si las unidades ya vienen agrupadas (barrios, municipios), los grupos hacen de bloques: *leave-location-out* CV.

CV espacial: ¿qué cambia y qué no?

- El algoritmo es el mismo: partir, entrenar, validar, promediar. Lo único que cambia es **cómo se arman los folds**.
- En R: `spatialsample` trae `spatial_block_cv()`, `spatial_buffer_vfold_cv()` y `spatial_leave_location_out_cv()`.
- El costo: el error estimado sube. No es que el modelo empeore; es que ahora lo estamos midiendo bien.
- También cambia la elección de hiperparámetros: con CV aleatoria se premia al modelo que mejor memoriza el ruido local; con CV espacial, al que mejor generaliza a lugares nuevos.

Ejemplo: CV espacial con Ames



photo from https://www.dailydot.com/parsec/batman-1966-labels-tumblr-twitter-vine/

Agenda

1. Motivación
2. Datos espaciales
3. Dependencia espacial
4. Validación cruzada espacial
5. Imágenes satelitales
6. Transfer learning
7. Aplicaciones
8. Cierre

Imágenes satelitales como datos

- Una imagen satelital es un raster con varias **bandas**: rojo, verde, azul, infrarrojo... Para una CNN, son canales.
- Hay imágenes gratuitas de todo el planeta, repetidas en el tiempo: Landsat (30 m), Sentinel-2 (10 m), luces nocturnas.
- El problema en ciencias sociales suele ser que los *labels* son escasos.

Ejemplo: Datos Satelitales



photo from https://www.dailydot.com/parsec/batman-1966-labels-tumblr-twitter-vine/

Agenda

1. Motivación
2. Datos espaciales
3. Dependencia espacial
4. Validación cruzada espacial
5. Imágenes satelitales
6. Transfer learning
7. Aplicaciones
8. Cierre

¿Por qué no entrenar desde cero?

- AlexNet: unos 60 millones de parámetros, entrenados con 1,2 millones de imágenes etiquetadas.
- Una encuesta de hogares: unos pocos miles de lugares con label.
- Es el problema de siempre: $p >> n$.
- Pero lo escaso son los *labels*, no las imágenes.
- Los bordes, texturas y formas que detecta una red no dependen mucho de la tarea.

Transfer learning

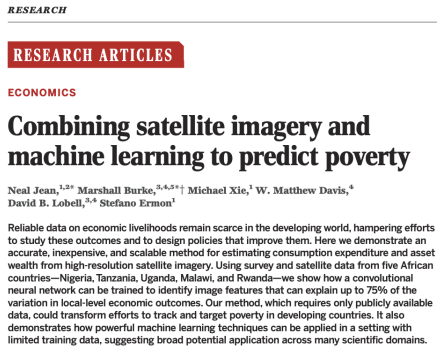
- Dos dominios: una **fuente**, con muchos labels (ImageNet), y un **objetivo**, con pocos .
- **Transfer learning**: tomamos una red entrenada en la fuente (p.ej. ResNet, MobileNet) y
  1. **congelamos** sus capas convolucionales y entrenamos solo una capa final nueva para nuestra tarea, o
  2. ajustamos (*fine-tune*) también algunas de las últimas capas, con una tasa de aprendizaje pequeña.
- La penúltima capa es un vector de **rasgos** (*embedding*) de la imagen, $\phi(x)$. Ese vector se puede usar como X en cualquier modelo: Ridge, XGBoost, ...

Agenda

1. Motivación
2. Datos espaciales
3. Dependencia espacial
4. Validación cruzada espacial
5. Imágenes satelitales
6. Transfer learning
7. Aplicaciones
8. Cierre

Pobreza desde el espacio

Jean, Burke, Xie, Davis, Lobell & Ermon (2016), *Science*



RESEARCH

RESEARCH ARTICLES

ECONOMICS

Combining satellite imagery and machine learning to predict poverty

Neal Jean,[1,2*] Marshall Burke,[3,4,5*†] Michael Xie,[1] W. Matthew Davis,[4] David B. Lobell,[3,4] Stefano Ermon[1]

Reliable data on economic livelihoods remain scarce in the developing world, hampering efforts to study these outcomes and to design policies that improve them. Here we demonstrate an accurate, inexpensive, and scalable method for estimating consumption expenditure and asset wealth from high-resolution satellite imagery. Using survey and satellite data from five African countries—Nigeria, Tanzania, Uganda, Malawi, and Rwanda—we show how a convolutional neural network can be trained to identify image features that can explain up to 75% of the variation in local-level economic outcomes. Our method, which requires only publicly available data, could transform efforts to track and target poverty in developing countries. It also demonstrates how powerful machine learning techniques can be applied in a setting with limited training data, suggesting broad potential application across many scientific domains.

https://cs.stanford.edu/~ermon/papers/JeanEtAl2016.pdf

Riqueza en África

Yeh, Perez, Driscoll, Azzari, Tang, Lobell, Ermon & Burke (2020), *Nature Communications*

Article | Open access | Published: 22 May 2020

Using publicly available satellite imagery and deep learning to understand economic well-being in Africa

Christopher Yeh, Anthony Perez, Anne Driscoll, George Azzari, Zhongyi Tang, David Lobell, Stefano Ermon & Marshall Burke

Nature Communications **11**, Article number: 2583 (2020) | Cite this article

Save article

78k Accesses | **459** Citations | **466** Altmetric | Metrics

Abstract

Accurate and comprehensive measurements of economic well-being are fundamental inputs into both research and policy, but such measures are unavailable at a local level in many parts of the world. Here we train deep learning models to predict survey-based estimates of asset wealth across ~ 20,000 African villages from publicly-available multispectral satellite imagery. Models can explain 70% of the variation in ground-measured village wealth in countries where the model was not trained, outperforming previous benchmarks from high-resolution imagery, and comparison with independent wealth measurements from censuses suggests that errors in satellite estimates are comparable to errors in existing ground data. Satellite-based estimates can also explain up to 50% of the variation in district-aggregated changes in wealth over time, with daytime imagery particularly useful in this task. We demonstrate the utility of satellite-based estimates for research and policy, and demonstrate their scalability by creating a wealth map for Africa's most populous country.

https://www.nature.com/articles/s41467-020-16185-w

Combining satellite imagery with machine learning (SIML)

Rolf, Proctor, Carleton, Bolliger, Shankar, Ishihara, Recht & Hsiang (2021), *Nature Communications*

Article | Open access | Published: 20 July 2021

A generalizable and accessible approach to machine learning with global satellite imagery

Esther Rolf, Jonathan Proctor, Tamma Carleton, Ian Bolliger, Vaishaal Shankar, Miyabi Ishihara, Benjamin Recht & Solomon Hsiang

Nature Communications **12**, Article number: 4392 (2021) | Cite this article

Save article

64k Accesses | **185** Citations | **148** Altmetric | Metrics

Abstract

Combining satellite imagery with machine learning (SIML) has the potential to address global challenges by remotely estimating socioeconomic and environmental conditions in data-poor regions, yet the resource requirements of SIML limit its accessibility and use. We show that a single encoding of satellite imagery can generalize across diverse prediction tasks (e.g., forest cover, house price, road length). Our method achieves accuracy competitive with deep neural networks at orders of magnitude lower computational cost, scales globally, delivers label super-resolution predictions, and facilitates characterizations of uncertainty. Since image encodings are shared across tasks, they can be centrally computed and distributed to unlimited researchers, who need only fit a linear regression to their own ground truth data in order to achieve state-of-the-art SIML performance.

https://www.nature.com/articles/s41467-021-24638-z

Agenda

1. Motivación
2. Datos espaciales
3. Dependencia espacial
4. Validación cruzada espacial
5. Imágenes satelitales
6. Transfer learning
7. Aplicaciones
8. Cierre

Recap

- La ubicación entra al modelo de dos maneras: variables y dependencia.
- Con dependencia espacial y un modelo flexible, la CV aleatoria subestima el error en $2\sigma^2\rho$. La CV espacial (bloques, buffers, leave-location-out) busca romper la dependencia espacial.
- Transfer learning nos ayuda a utilizar una representación aprendida en otra parte
- Próxima clase: **texto como datos**.